# Review : Deep Residual Learning for Image Recognition

## 1 문제 정의

네트워크가 깊어질수록 오히려 training error가 증가하는 degradation problem이 발생한다. 이는 optimizer가 깊은 네트워크에서 좋은 해를 찾지 못하는 최적화 문제이다. 예를 들어 20-layer 위에 레이어를 더 쌓은 56-layer는, 추가 레이어가 입력을 그대로 통과시키기만 해도 20-layer와 동일한 성능이 나와야 한다. 그러나 실제로는 56-layer의 training error가 더 높다.

## 2 접근 방식

기존 방식은 레이어가 목표 함수 $\mathcal{H}(x)$를 직접 학습한다. ResNet은 대신 레이어가 $\mathcal{F}(x) = \mathcal{H}(x) - x$, 즉 목표값에서 입력을 뺀 잔차만 학습하도록 바꾼다.

최종 출력은 아래와 같다.

$$y = \mathcal{F}(x, \{W_i\}) + x \tag{1}$$

입력 $x$를 레이어를 건너뛰어 출력에 더해주는 shortcut connection으로 구현된다. 만약 identity mapping이 최적인 경우 $\mathcal{F}(x) \to 0$으로 수렴하면 되므로 최적화가 단순해진다. shortcut connection은 파라미터와 연산량을 추가하지 않는다.

## 3 데이터셋

- **ImageNet ILSVRC 2012**: 1,000 classes, 훈련 128만 장, 검증 5만 장, 테스트 10만 장
- **CIFAR-10**: 10 classes, 훈련 5만 장, 테스트 1만 장
- **PASCAL VOC 2007/2012**: object detection 평가용
- **MS COCO**: 80 categories, object detection 및 segmentation 평가용

# 4 모델 구조

제시된 모델은 ResNet-18, 34, 50, 101, 152가 있다. Figure 1을 보면 ResNet 공통 구조를 확인할 수 있다. 레이어 개수는 파라미터가 있는 레이어만 개수를 세서 7×7 conv(1개), fc 1000(1개) 2개는 기본으로 블럭에서 레이어 개수만 달라진다. block 구조는 레이어개수에 따라 다르다 block은 Building Block, Bottleneck Block 크게 두 개가 있다.

Table 1에서 FLOPs는 연산량으로 값이 클 수록 더 오래 걸리고 메모리도 많이 사용한다.

Figure 1: structure

| 모델 | 레이어 수 | FLOPs |
|---|---|---|
| ResNet-18 | 18 | $1.8 \times 10^9$ |
| ResNet-34 | 34 | $3.6 \times 10^9$ |
| ResNet-50 | 50 | $3.8 \times 10^9$ |
| ResNet-101 | 101 | $7.6 \times 10^9$ |
| ResNet-152 | 152 | $11.3 \times 10^9$ |

Table 1: ResNet 모델별 레이어 및 연산량

## 4.1 Block

Figure 2은 Building Block 구조로 ResNet 18과 34에서 사용됐다. 한 블럭의 $3 \times 3$ conv 레이어가 두 개가 들어가있다. ResNet-18은 기본 구조 2레이어를 제외한 16 레이어 즉, 8블럭을 사용했다. ResNet-34은 기본 구조 2레이어를 제외한 32레이어 즉, 16블럭을 사용했다.

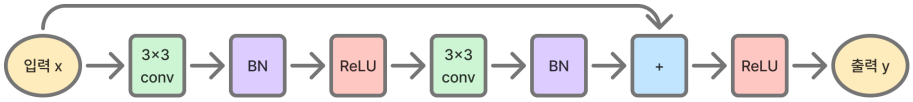


Figure 2: Building Block

Figure 3은 Bottleneck Block으로 ResNet-50, 101, 152에서 사용됐다. 한 블럭의 레이어 3개가 들어가있다. 레이어 50개 이상으로 깊어지면 Building Block를 쓰기에는 연산량이 너무 커져서 채널을 $1 \times 1$로 줄이고 conv 레이어 통과 후 다시 $1 \times 1$로 복원 하는 방식으로 바꾼다. 예를 들어 256 채널짜리 입력에 $3 \times 3$ conv를 적용하면 연산량이 크지만 $1 \times 1$로 64 채널로 줄이고 conv를 적용하면 연산량이 약

9배 감소하면서도 성능이 비슷하게 유지된다. ResNet-50은 기본 2레이어를 제외한 48레이어 즉, 16블럭을 사용했다. ResNet-101은 기본 2레이어를 제외한 99레이어 즉, 33블럭을 사용했다. ResNet-152은 기본 2레이어를 제외한 150레이어 즉, 50블럭을 사용했다.

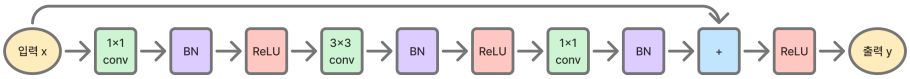


Figure 3: Bottleneck Block

### 4.2 Projection Shortcut

shortcut의 x는 64채널인데 F(x)는 128채널이라 그냥 더할 수 없다. 그래서 1×1 conv로 채널 수를 맞춰준 다음 더하는 게 projection shortcut이다. 단순 F(X)+x 에서 x의 채널을 맞춰주는 것이다.

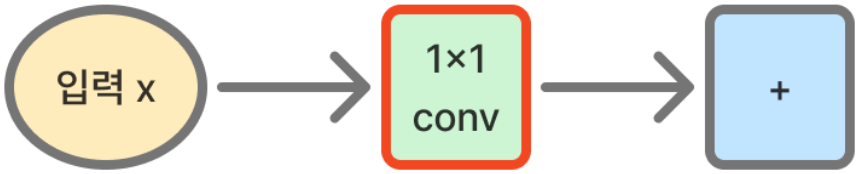


Figure 4: Projection Shortcut

## 5 평가 지표

- **Top-1 / Top-5 error (%)**: ImageNet classification
- **mAP@.5**: PASCAL VOC 및 COCO object detection
- **mAP@[.5, .95]**: COCO standard metric
- **Top-5 localization error (%)**: ImageNet localization

## 6 주요 결과

- ResNet-152: ImageNet top-5 error **4.49%** (single model)
- 앙상블: ImageNet top-5 error **3.57%** → ILSVRC 2015 classification 1위
- plain-34 대비 ResNet-34: top-1 error 3.5% 감소
- COCO object detection: VGG-16 대비 mAP@[.5,.95] **28% 상대적 향상**

- CIFAR-10: ResNet-110에서 6.43% error 달성
- ILSVRC & COCO 2015 detection, localization, segmentation 전 부문 1위

# 7 한계

- degradation problem의 정확한 원인이 이론적으로 규명되지 않음 (향후 연구 과제로 남김)
- 1202-layer 모델에서 110-layer보다 test error가 높아짐 → 소규모 데이터셋에서 과적합 발생, dropout 등 강한 정규화 없이는 한계 존재
- 매우 깊은 네트워크에서 초기 learning rate 조정이 필요함 (110-layer: warm-up 필요)